

XML: eXtensible Markup Languaje

Tecnologías XML

XPath

Dr. Juan Manuel Cueva Lovelle
Departamento de Informática
Universidad de Oviedo
cueva@uniovi.es

Software y estándares para la Web

Esquema

- Introducción a XPath
- XPath
- Conclusiones
- Bibliografía
- Referencias Web
- Ejercicios resueltos

Grado en Ingeniería Informática del software

Escuela de Ingeniería Informática
Universidad de Oviedo

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Esquema

- **Introducción a XPath**
- Xpath
- Conclusiones
- Bibliografía
- Referencias Web
- Ejercicios resueltos

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Introducción a XPath

- **XPath** o XML Path Language*: **sintaxis (no basada en XML) para acceder o referirse a porciones de un documento XML***

- **W3C Recommendation 14 December 2010** ***(Link errors corrected 3 January 2011; Status updated October 2016)***
  - **https://www.w3.org/TR/xpath20/**

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Esquema

- Introducción a XPath
- **XPath**
- Conclusiones
- Bibliografía
- Referencias Web
- Ejercicios resueltos

Grado en Ingeniería Informática del software

Escuela de Ingeniería Informática
Universidad de Oviedo

XPath (I): Objetivo

- Objetivo: Identificar a los elementos del árbol DOM de XML
- Tienen la forma
  - nodo1/nodo2/.../nodoN
- Ejemplo: persona/apellido/materno
- Describen un camino (*path*)
- Resultado:
  - Un conjunto de nodos
  - String, número o boolean
- Es un estándar del W3C
  - http://www.w3.org/TR/xpath20/

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

XPath(II): XPath versus Sistema de Archivos

Archivos y directorios	Nodos dentro de nodos
Respecto a directorio actual	Respecto a nodo actual o de contexto
* = cualquier cosa	* = cualquier nodo
Un archivo por ruta	Uno o varios nodos por ruta

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

XPath (III): Resumen de sintaxis abreviada XPath

- **X** → elemento X (hijo del nodo actual).
- ***** → todos los elementos hijo del nodo actual.
- **text()** → nodos de texto hijos del nodo actual.
- **@Y** → atributo Y.
- **X[1]** → primer elemento X entre sus hermanos del mismo nombre.
- **X[last()]** → último elemento X entre sus hermanos del mismo nombre.
- ***/X** → elementos X hijos de cualquier hijo del nodo actual
- **X//Y** → elementos Y descendientes de un elemento X.
- **//Y** → todos los elementos Y descendientes del documento (desde la raíz).
- **//Y/X** → elementos X hijos directos de elementos Y encontrados en cualquier lugar del documento.
- **..** → nodo padre.
- **.** → nodo actual.
- **//X[1][@Y='Z']** → elementos X que son el primer X entre sus hermanos y tienen el atributo Y='Z'.

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

XPath (IV): Ejemplo **biblioteca.xml** y **biblioteca.dtd**


```xml
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE biblioteca SYSTEM "biblioteca.dtd">
<biblioteca>
  <libro id="ISBN-978-84-376-0494-7">
    <titulo>Cien años de soledad</titulo>
    <autor>Gabriel García Márquez</autor>
    <editorial>Editorial Sudamericana</editorial>
    <anio>1967</anio>
    <isbn>978-84-376-0494-7</isbn>
  </libro>
  <libro id="ISBN-978-84-339-7882-0">
    <titulo>1984</titulo>
    <autor>George Orwell</autor>
    <editorial>Editorial Debolsillo</editorial>
    <anio>1949</anio>
    <isbn>978-84-339-7882-0</isbn>
  </libro>
  <libro id="ISBN-978-84-670-5191-1">
    <titulo>El gran Gatsby</titulo>
    <autor>F. Scott Fitzgerald</autor>
    <editorial>Editorial Planeta</editorial>
    <anio>1925</anio>
    <isbn>978-84-670-5191-1</isbn>
  </libro>
</biblioteca>
```

```dtd
<!ELEMENT biblioteca (libro+)>
<!ELEMENT libro (titulo, autor, editorial, anio, isbn)>
<!ATTLIST libro id ID #REQUIRED>
<!ELEMENT titulo (#PCDATA)>
<!ELEMENT autor (#PCDATA)>
<!ELEMENT editorial (#PCDATA)>
<!ELEMENT anio (#PCDATA)>
<!ELEMENT isbn (#PCDATA)>
```

Escuela de Ingeniería Informática
Universidad de Oviedo

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

XPath (V): Funciones XPath más comunes

Función	Descripción	Ejemplo de uso
last()	Devuelve la posición del último nodo en el conjunto	/biblioteca/libro[last()] → Último libro
position()	Devuelve la posición del nodo actual	/biblioteca/libro[position() = 2] → Segundo libro
count()	Cuenta el número de nodos seleccionados	count(/biblioteca/libro) → Total de libros
contains()	Verifica si una cadena contiene otra	/libro[contains(editorial, 'Planeta')] → Libros de esa editorial
starts-with()	Verifica si una cadena comienza con otra	/libro[starts-with(@id, 'ISBN-978')] → Libros con ese prefijo en el ID
substring()	Extrae una parte de una cadena	substring(titulo, 1, 4) → Primeras 4 letras del título
string-length()	Devuelve la longitud de una cadena	string-length(autor) → Número de caracteres del nombre del autor
normalize-space()	Elimina espacios en blanco innecesarios	normalize-space(titulo) → Título sin espacios extra
not()	Niega una condición lógica	/libro[not(anio > 2000)] → Libros publicados en o antes del año 2000
name()	Devuelve el nombre del nodo	name(/biblioteca/libro[1]) → "libro"

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

XPath (VI): Expresiones Xpath de **biblioteca.xml**

- Selecciona los libros escritos por George Orwell
  /biblioteca/libro[autor='George Orwell']
- Seleccionar el último libro publicado
  /biblioteca/libro[not(anio < //libro/anio)][last()]
- Libros cuyo atributo id empieza por "ISBN-978-84-339“
  /biblioteca/libro[starts-with(@id, 'ISBN-978-84-339')]
- Libros publicados antes de 1958 y cuya editorial contiene "Planeta“
  /biblioteca/libro[anio < 1958 and contains(editorial, 'Planeta')]
- Seleccionar el segundo libro en la lista
  /biblioteca/libro[position() = 2]
- Extrae los últimos 6 caracteres del ISBN y los compara.
  /biblioteca/libro[substring(isbn, string-length(isbn) - 5) = '5191-1']

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Esquema

- Introducción a XPath
- XPath
- **Conclusiones**
- Bibliografía
- Referencias Web
- Ejercicios resueltos

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Conclusiones

- **XPath** o XML Path Language*: **sintaxis (no basada en XML) para acceder o referirse a porciones de un documento XML***

- **W3C Recommendation 14 December 2010 *(Link errors corrected 3 January 2011; Status updated October 2016)***
  - **https://www.w3.org/TR/xpath20/**

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Esquema

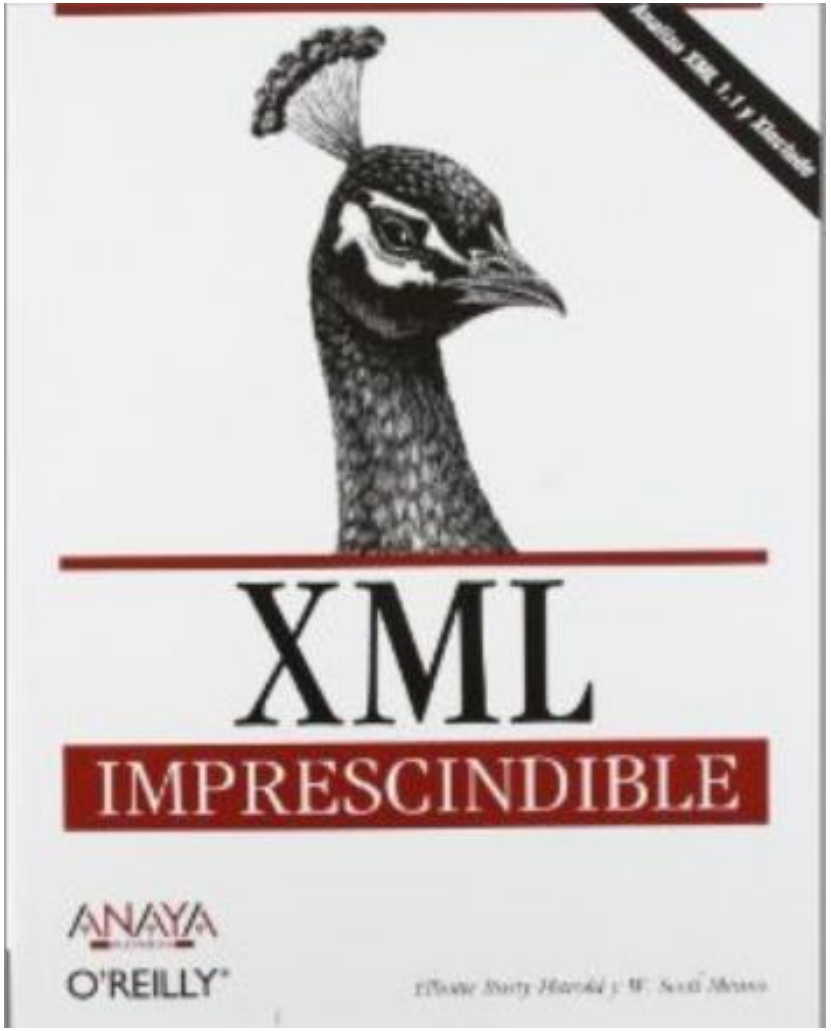
- Introducción a XPath
- XPath
- Conclusiones
- **Bibliografía**
- Referencias Web
- Ejercicios resueltos

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Bibliografía (I)

- Libro recomendado de lectura y consulta:
  - "**XML imprescindible**"
  - ANAYA/O'Reilly (2005)
  - E. Rusty Harold y W. Scott Means



Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Bibliografía (II)

- Libro recomendado de consulta:
  - "**Beginning XML**"
  - John Wiley & Sons (2012)
  - Joe Fawcett, Liam R.E. Quin, and Danny Ayers



Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Esquema

- Introducción a XPath
- XPath
- Conclusiones
- Bibliografía
- **Referencias Web**
- Ejercicios resueltos

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Referencias Web

- XPath en el W3C
  - https://www.w3.org/TR/xpath20/
- Tutorial
  - https://www.w3schools.com/xml/xpath_intro.asp

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Esquema

- Introducción a XPath
- XPath
- Conclusiones
- Bibliografía
- Referencias Web
- **Ejercicios resueltos**
  - **xml.etree.ElementTree**
  - lxml

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (I): Biblioteca **xml.etree.ElementTree**

- Dado un archivo XML obtener los nodos del árbol DOM de una expresión XPath dada
  - Se utilizará el lenguaje Python con la biblioteca estándar **xml.etree.ElementTree**
  - Esta biblioteca tiene **soporte limitado** de XPath. Admite:
    - Selección de nodos por nombre: 'tag', './tag', 'tag/subtag'
    - Selección relativa: './' para indicar el nodo actual
    - Selección de todos los hijos: '//*', './*'
    - Selección por atributo: 'tag[@attr="value"]'
    - Selección por posición: 'tag[1]' (índice basado en 1)
  - No se admiten expresiones más avanzadas como:
    - Funciones XPath (contains(), starts-with(), etc.)
    - Operadores lógicos (and, or)
    - Expresiones condicionales complejas
    - Selección de nodos por texto (text())
    - Ejes XPath como ancestor, preceding-sibling, etc.
  - Biblioteca alternativa
    - **lxml**: Un módulo más potente que soporta XPath completo.

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (II):Biblioteca **xml.etree.ElementTree**

Grado en Ingeniería Informática del software

```
# 02010-XPath.py
# # -*- coding: utf-8 -*-
"""
Ejemplos de uso de XPath

@version 1.2 21/Octubre/2020
@author: Juan Manuel Cueva Lovelle. Universidad de Oviedo
"""
import xml.etree.ElementTree as ET

def verXPath(archivoXML, expresionXPath):
    """Función verXPath(archivoXML, expresionXPath)
Visualiza por pantalla el nodo correspondiente de una expresión XPath de un archivo XML

Version: 1.2 21/Octubre/2020
Author: Juan Manuel Cueva Lovelle. Universidad de Oviedo
    """
    try:

        arbol = ET.parse(archivoXML)

    except IOError:
        print ('No se encuentra el archivo ', archivoXML)
        exit()

    except ET.ParseError:
        print("Error procesando en el archivo XML = ", archivoXML)
        exit()
```

Escuela de Ingeniería Informática
Universidad de Oviedo

Software y estándares para la Web

Ejercicios resueltos (III): Biblioteca **xml.etree.ElementTree**

Grado en Ingeniería Informática del software

```
    raiz = arbol.getroot()

    # Recorrido de los elementos del árbol
    for hijo in raiz.findall(expresionXPath): # Expresión XPath
        print("\nElemento = " , hijo.tag)
        if hijo.text != None:
            print("Contenido = ", hijo.text.strip('\n')) #strip() elimina los '\n' del string
        else:
            print("Contenido = ", hijo.text)
        print("Atributos = ", hijo.attrib)

def main():
    """Prueba de la función verXPath()"""

    print(verXPath.__doc__)

    miArchivoXML = input('Introduzca un archivo XML = ')

    miExpresionXPath = input('Introduzca la expresión XPath = ')

    verXPath(miArchivoXML, miExpresionXPath)

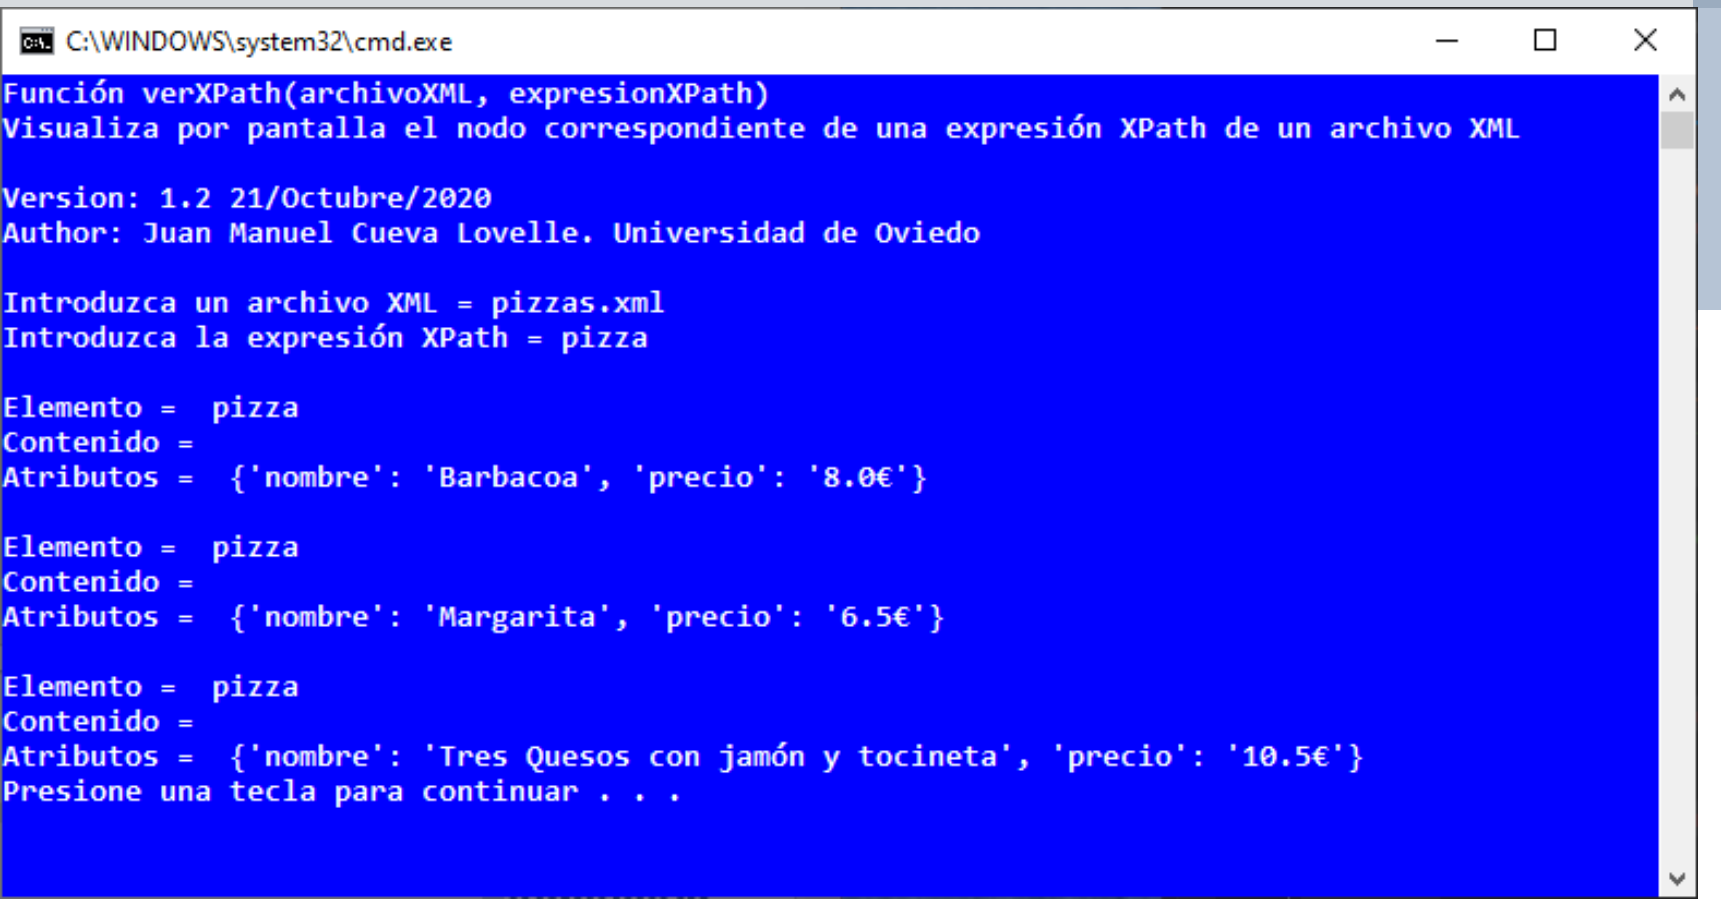
if __name__ == "__main__":
    main()
```

Escuela de Ingeniería Informática
Universidad de Oviedo

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (IV): **pizzas.xml** y expresión=**pizza**

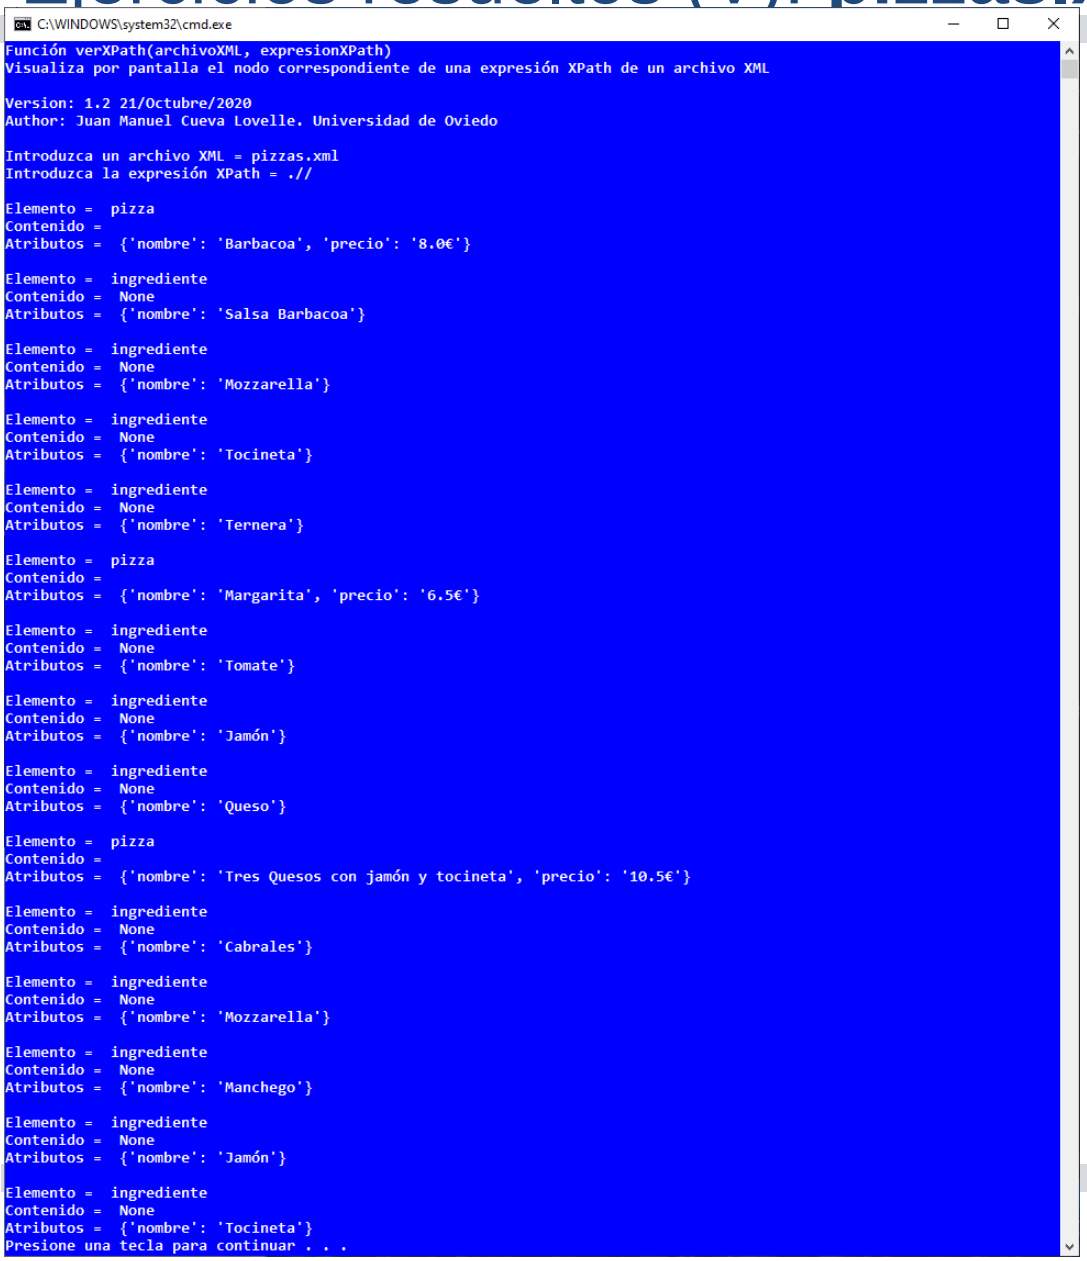


Grado en Ingeniería Informática del software

Escuela de Ingeniería Informática
Universidad de Oviedo

Software y estándares para la Web

Ejercicios resueltos (V): **pizzas.xml** y expresión= **.//**



Grado en Ingeniería Informática del software

Escuela de Ingeniería Informática
Universidad de Oviedo

Software y estándares para la Web

Ejercicios resueltos (VI): **pizzas-xsd.xml**

- En el ejemplo **pizzas-xsd.xml** se utiliza el XML esquema **pizzas.xsd**
- Observese que cuando se usan los XML esquemas aparece el prefijo de los elementos en las expresiones XPath

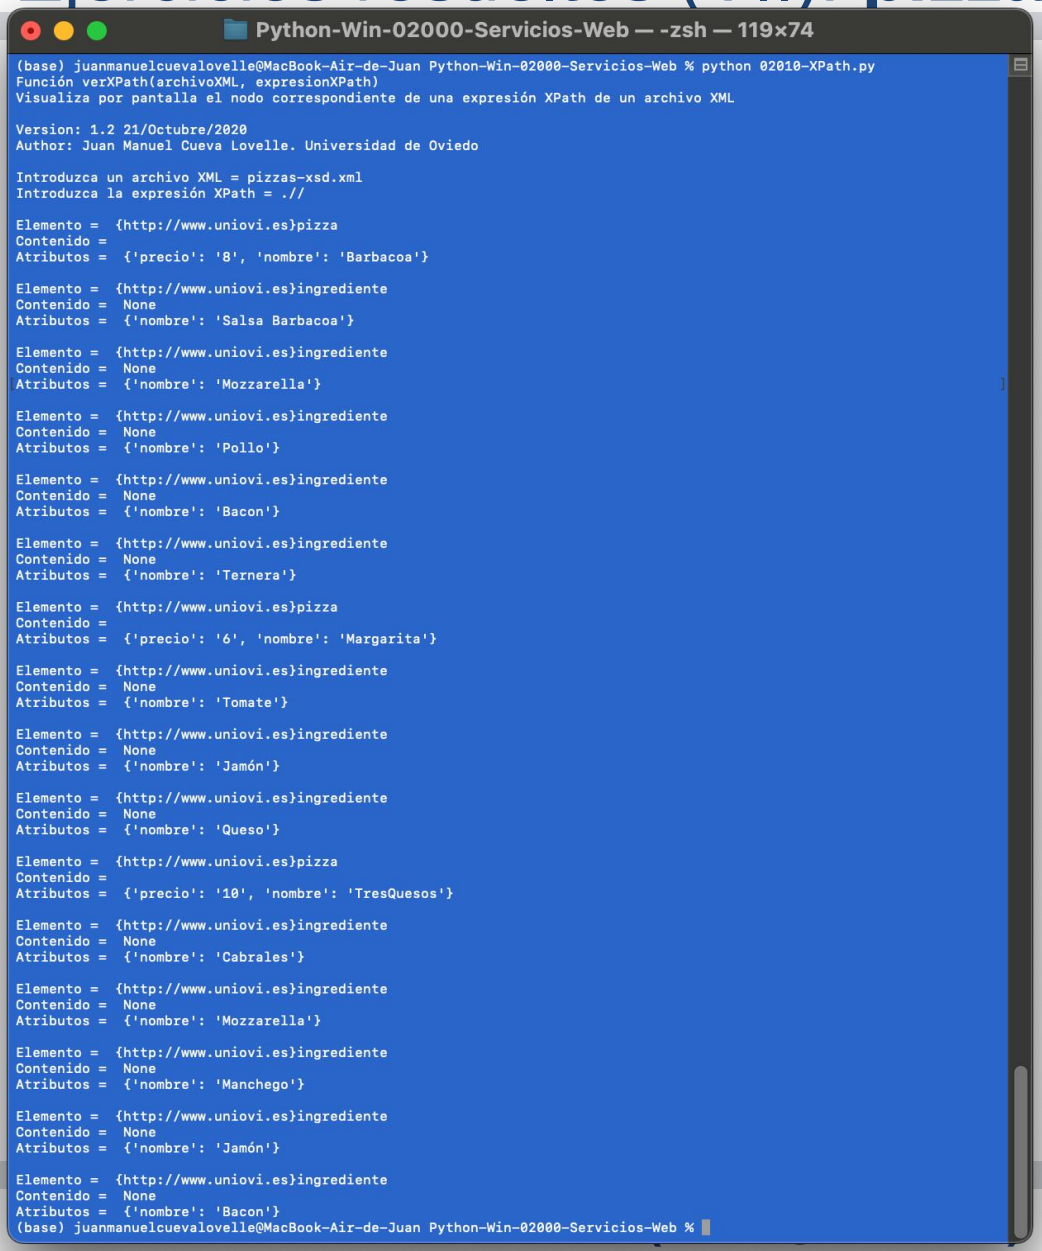
```
{http://www.uniovi.es}pizza
```


Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (VII): **pizzas-xsd.xml** y expresión= **.//**

Grado en Ingeniería Informática del software



Escuela de Ingeniería Informática
Universidad de Oviedo

Software y estándares para la Web

Ejercicios resueltos (VIII): **pizzas-xsd.xml** y expresión={http://www.uniovi.es}pizza

Python-Win-02000-Servicios-Web — -zsh — 114×22

```
(base) juanmanuelcuevalovelle@MacBook-Air-de-Juan Python-Win-02000-Servicios-Web % python 02010-XPath.py
Función verXPath(archivoXML, expresionXPath)
Visualiza por pantalla el nodo correspondiente de una expresión XPath de un archivo XML

Version: 1.2 21/Octubre/2020
Author: Juan Manuel Cueva Lovelle. Universidad de Oviedo

Introduzca un archivo XML = pizzas-xsd.xml
Introduzca la expresión XPath = {http://www.uniovi.es}pizza

Elemento =  {http://www.uniovi.es}pizza
Contenido =
Atributos =  {'precio': '8', 'nombre': 'Barbacoa'}

Elemento =  {http://www.uniovi.es}pizza
Contenido =
Atributos =  {'precio': '6', 'nombre': 'Margarita'}

Elemento =  {http://www.uniovi.es}pizza
Contenido =
Atributos =  {'precio': '10', 'nombre': 'TresQuesos'}
(base) juanmanuelcuevalovelle@MacBook-Air-de-Juan Python-Win-02000-Servicios-Web %
```

Escuela de Ingeniería Informática
Universidad de Oviedo

Esquema

- Introducción a XPath
- XPath
- Conclusiones
- Bibliografía
- Referencias Web
- **Ejercicios resueltos**
  - xml.etree.ElementTree
  - **lxml**

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (I): Biblioteca **lxml**

- Dado un archivo XML obtener los nodos del árbol DOM de una expresión XPath dada
  - Se utilizará el lenguaje **Python** con la biblioteca **lxml**
  - La biblioteca **lxml** es necesario instalarla, no es estándar de Python
  - Admiten expresiones avanzadas como:
    - Funciones XPath (contains(), starts-with(), etc.)
    - Operadores lógicos (and, or)
    - Expresiones condicionales complejas
    - Selección de nodos por texto (text())
    - Ejes XPath como ancestor, preceding-sibling, etc.
    - Ejemplo de uso:

```
from lxml import etree

# Cargar el archivo XML
tree = etree.parse('ejemplo.xml')
root = tree.getroot()

# Buscar todos los títulos
titulos = tree.xpath('//titulo')
for t in titulos:
    print(t.text)
```


Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (II): Ejemplo **biblioteca.xml** y **biblioteca.dtd**

Grado en Ingeniería Informática del software

```xml
<?xml version="1.0" encoding="UTF-8"?>
<!DOCTYPE biblioteca SYSTEM "biblioteca.dtd">
<biblioteca>
  <libro id="ISBN-978-84-376-0494-7">
    <titulo>Cien años de soledad</titulo>
    <autor>Gabriel García Márquez</autor>
    <editorial>Editorial Sudamericana</editorial>
    <anio>1967</anio>
    <isbn>978-84-376-0494-7</isbn>
  </libro>
  <libro id="ISBN-978-84-339-7882-0">
    <titulo>1984</titulo>
    <autor>George Orwell</autor>
    <editorial>Editorial Debolsillo</editorial>
    <anio>1949</anio>
    <isbn>978-84-339-7882-0</isbn>
  </libro>
  <libro id="ISBN-978-84-670-5191-1">
    <titulo>El gran Gatsby</titulo>
    <autor>F. Scott Fitzgerald</autor>
    <editorial>Editorial Planeta</editorial>
    <anio>1925</anio>
    <isbn>978-84-670-5191-1</isbn>
  </libro>
</biblioteca>
```

```dtd
<!ELEMENT biblioteca (libro+)>
<!ELEMENT libro (titulo, autor, editorial, anio, isbn)>
<!ATTLIST libro id ID #REQUIRED>
<!ELEMENT titulo (#PCDATA)>
<!ELEMENT autor (#PCDATA)>
<!ELEMENT editorial (#PCDATA)>
<!ELEMENT anio (#PCDATA)>
<!ELEMENT isbn (#PCDATA)>
```

Escuela de Ingeniería Informática
Universidad de Oviedo

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (III): Ejemplos de expresiones XPath

- Editorial de libros cuyo título contiene la palabra "Gatsby"
  //libro[contains(titulo, 'Gatsby')]/editorial
- Libros cuyo autor contiene el nombre 'Gabriel'
  //libro[contains(autor, 'Gabriel')]
- Todos los elementos hijos de cada libro
  //libro/*
- Título del libro con ISBN específico
  //libro[isbn='978-84-339-7882-0']/titulo
- Libros cuyo autor es George Orwell
  //libro[autor='George Orwell']
- Libros publicados antes del año 1950
  //libro[number(anio) < 1950]
- ISBN de todos los libros
  //isbn
- Autores de todos los libros
  //autor
- Todos los títulos de libros
  //titulo

Escuela de Ingeniería Informática
Universidad de Oviedo

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (IV): 02015-XPath-lxml.py

```python
# 02015-XPath-lxml.py
# -*- coding: utf-8 -*-
"""
Ejemplos de uso de XPath con lxml
Sin utilizar espacios de nombres
Posiblemente tenga que instalar lxml
Ventajas de lxml: maneja expresiones XPath complejas
@version 1.3 19/Octubre/2025
@author: Juan Manuel Cueva Lovelle. Universidad de Oviedo
"""
from lxml import etree

def verXPath(archivoXML, expresionXPath):
    """
    Función verXPath(archivoXML, expresionXPath)
    Visualiza por pantalla el nodo correspondiente de una expresión XPath de un archivo XML usando lxml
    Version: 1.3 19/Octubre/2025
    Author: Juan Manuel Cueva Lovelle. Universidad de Oviedo
    """
    print("\nArchivo XML     = " + archivoXML)
    print("Expresion XPath = " + expresionXPath)
    try:
        with open(archivoXML, 'rb') as f:
            arbol = etree.parse(f)
    except IOError:
        print('No se encuentra el archivo', archivoXML)
        exit()
    except etree.XMLSyntaxError:
        print("Error procesando el archivo XML =", archivoXML)
        exit()
    # Evaluación de la expresión XPath
    elementos = arbol.xpath(expresionXPath)
    for hijo in elementos:
        if isinstance(hijo, etree._Element):
            print("\nElemento =", hijo.tag)
            texto = hijo.text.strip() if hijo.text else None
            print("Contenido =", texto)
            print("Atributos =", hijo.attrib)
        else:
            print("\nResultado XPath =", hijo)
```

Grado en Ingeniería Informática del software

Escuela de Ingeniería Informática
Universidad de Oviedo

Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (V): 02015-XPath-lxml.py

```
def main():
    """Prueba de la función verXPath()"""
    print(verXPath.__doc__)

    """ miArchivoXML = input('Introduzca un archivo XML = ')"""
    miArchivoXML = "biblioteca.xml"

    """miExpresionXPath = input('Introduzca la expresión XPath = ')"""
    miExpresionXPath = "//libro[contains(titulo, 'Gatsby')]/autor"

    verXPath(miArchivoXML, miExpresionXPath)

    """Otros ejemplos"""

    verXPath("biblioteca.xml", "//libro[number(anio) < 1958]/titulo")

    verXPath("biblioteca.xml", "//libro[isbn='978-84-339-7882-0']/titulo")

    """
    /biblioteca/libro[contains(@id, 'ISBN')][last()]

    /biblioteca/libro: selecciona todos los elementos <libro> que están directamente dentro de <biblioteca>.
    [contains(@id, 'ISBN')]: filtra esos libros para que solo se incluyan aquellos cuyo atributo id contiene la cadena "ISBN".
    [last()]: selecciona el último de esos elementos filtrados.
    /titulo: muestra el elemento titulo
    """
    verXPath("biblioteca.xml", "/biblioteca/libro[contains(@id, 'ISBN')][last()]/titulo")

    """
    Encuentra el título del libro más reciente (último año) y luego selecciona el último si hay varios con ese año.
    /biblioteca/libro[not(anio < //libro/anio)][last()]/titulo
    """
    verXPath("biblioteca.xml", "/biblioteca/libro[not(anio < //libro/anio)][last()]/titulo")


if __name__ == "__main__":
    main()
```


Dr. Juan Manuel Cueva Lovelle (cueva@uniovi.es)

Software y estándares para la Web

Ejercicios resueltos (VI): Ejecución de **02015-XPath-lxml.py**

Windows PowerShe

```
PS C:\Users\cueva\Dropbox\Python-Win-02000-Servicios-Web> python 02015-XPath-lxml.py

    Función verXPath(archivoXML, expresionXPath)
    Visualiza por pantalla el nodo correspondiente de una expresión XPath de un archivo XML usando lxml

    Version: 1.3 19/Octubre/2025
    Author: Juan Manuel Cueva Lovelle. Universidad de Oviedo


Archivo XML     = biblioteca.xml
Expresion XPath = //libro[contains(titulo, 'Gatsby')]/autor

Elemento = autor
Contenido = F. Scott Fitzgerald
Atributos = {}

Archivo XML     = biblioteca.xml
Expresion XPath = //libro[number(anio) < 1958]/titulo

Elemento = titulo
Contenido = 1984
Atributos = {}

Elemento = titulo
Contenido = El gran Gatsby
Atributos = {}

Archivo XML     = biblioteca.xml
Expresion XPath = //libro[isbn='978-84-339-7882-0']/titulo

Elemento = titulo
Contenido = 1984
Atributos = {}

Archivo XML     = biblioteca.xml
Expresion XPath = /biblioteca/libro[contains(@id, 'ISBN')][last()]/titulo

Elemento = titulo
Contenido = El gran Gatsby
Atributos = {}

Archivo XML     = biblioteca.xml
Expresion XPath = /biblioteca/libro[not(anio < //libro/anio)][last()]/titulo

Elemento = titulo
Contenido = Cien años de soledad
Atributos = {}
```

Grado en Ingeniería Informática del software

Escuela de Ingeniería Informática
Universidad de Oviedo



XML: eXtensible Markup Languaje

Tecnologías XML

XPath

Dr. Juan Manuel Cueva Lovelle
Departamento de Informática
Universidad de Oviedo
cueva@uniovi.es